

Tài liệu Metadata đầy đủ: Trình mô phỏng nguồn nền tảng

Trieu Nguyen

Ngày 26 tháng 8 năm 2026


Contents

Tóm tắt	1
1. Phạm vi tài liệu	2
2. Metadata identity dùng chung	2
3. Metadata Meta Lead Ads	4
4. Metadata TikTok Integrated Reports	5
5. Metadata Google Analytics 4	7
6. Metadata Zalo Official Account	10
7. Metadata AppsFlyer Pull API Raw Data	11
8. Metadata CIR liên nền tảng	14
9. Thuật toán CIR liên nền tảng	15

Tóm tắt

Tài liệu này là hợp đồng metadata cho `all-data-simulator/full_raw_data_simulator.py`. Tài liệu mô tả nền tảng nguồn được đại diện bởi từng dataset, schema CSV được sinh ra, kiểu dữ liệu và ý nghĩa của từng field, giá trị định danh, cũng như khác biệt giữa payload thực tế của nền tảng và biểu diễn test dạng phẳng của trình mô phỏng này.

Sơ đồ luồng dữ liệu



1. Phạm vi tài liệu

Các dataset nguồn

Dataset	Nền tảng nguồn	Grain
meta_cir_api.csv	Meta Lead Ads	Một lead trên mỗi dòng
tiktok_cir_api.csv	TikTok Ads	Một dòng cho mỗi ad và ngày báo cáo
ga4_cir_api.csv	Google Analytics 4	Một dòng event/report tổng hợp giả lập
zalo_cir_api.csv	Zalo Official Account	Một dòng profile người dùng
appsflyer_cir_api.csv	AppsFlyer	Một event trong ứng dụng trên mỗi dòng

Danh mục generator

Generator	Dataset
generate_meta_data	meta_cir_api.csv
generate_tiktok_data	tiktok_cir_api.csv
generate_ga4_data	ga4_cir_api.csv
generate_zalo_data	zalo_cir_api.csv
generate_appsflyer_data	appsflyer_cir_api.csv

Metadata runtime và output

Hạng mục	Giá trị
Số dòng mặc định	20 dòng cho mỗi dataset
Số lượng identity dùng chung	8 người, được tái sử dụng theo chu kỳ
Ngày/giờ cơ sở	2026-08-01 09:00:00
Random seed	42
Encoding CSV	utf-8-sig (UTF-8 có BOM)
Chế độ xuống dòng CSV	newline=""
Thư mục output	all-data-simulator/platform_cir_csv/
ZIP archive	platform_cir_api_csv_simulated.zip trong thư mục all-data-simulator/
Nội dung ZIP	Năm file CSV được sinh ra, lưu bằng basename
Dictionary key bị thiếu	Bị bỏ qua bởi csv.DictWriter vì extrasaction="ignore"

Các output path tương đối được phân giải dựa trên thư mục làm việc của process, không dựa trên thư mục chứa script. Lệnh được ghi trong tài liệu này giả định thư mục làm việc là thư mục gốc của repository.

2. Metadata identity dùng chung

PEOPLE là nguồn identity giả lập được dùng để hỗ trợ identity resolution giữa các nền tảng. Với row index i , mỗi generator chọn $PEOPLE[i \% \text{len}(\text{PEOPLE})]$, ngoại trừ TikTok vì đây là dữ liệu quảng cáo tổng hợp và không sử dụng bản ghi của một cá nhân.

Attribute	Type	Ví dụ	Mục đích
cid	string	CUST-0001	Khóa customer giả lập; xuất hiện trong customer_user_id của AppsFlyer và JSON event_value
name	string	Nguyen An	Tên hiển thị đầy đủ cho Meta và Zalo
first	string	An	Tên gọi trong Meta lead
last	string	Nguyen	Họ trong Meta lead
email	string	an.nguyen@example.test	Email trong Meta lead; là dữ liệu giả lập và không gửi được
phone	string	84901234001	Số điện thoại Meta/Zalo; các chữ số được tạo theo dạng giống dữ liệu đã chuẩn hóa
city	string	Hanoi	Field ngữ cảnh địa lý và identity
state	string	Hanoi	Field ngữ cảnh địa lý và identity
country	string	VN	Mã quốc gia dạng ISO được dùng trong các row của nền tảng
gender	integer	1	Mã gender mô phỏng của Zalo; comment trong code quy định 1 là nam, 2 là nữ, 0 là khác/không xác định

Việc liên kết identity là dữ liệu giả lập. Các platform ID thực tế không được dùng làm customer key dùng chung. Các CIR key được mô phỏng mạnh nhất là email, phone, name và cặp customer_user_id/event_value.customer_id của AppsFlyer.

3. Metadata Meta Lead Ads

Nguồn tài liệu API

- Hướng dẫn chính: [Meta Lead Ads retrieval guide](#)
- Lead node: [Meta Lead object reference](#)
- Lead form: [Meta Leadgen Form reference](#)

Một Meta lead thực tế là một object. Các câu trả lời của form thường được biểu diễn trong collection lồng nhau có tên `field_data`. Trình mô phỏng này xuất ra projection CSV dạng phẳng để phục vụ ingestion và test CIR.

Metadata dataset

Hạng mục	Giá trị
File	<code>meta_cir_api.csv</code>
Grain	Một lead giả lập
Số dòng	<code>Config.NUM_ROWS</code>
Source identifier chính	<code>id</code>
Identity field	<code>field_email, field_phone, field_first_name, field_last_name, field_city, field_state, field_country</code>
Time field	<code>created_time</code>
Định dạng thời gian	<code>YYYY-MM-DDTHH:MM:SS+0000</code>
Flattening	Câu trả lời form trở thành các column <code>field_*</code> ; hierarchy campaign cũng được làm phẳng

Metadata column

Column	Type	Nullability	Ý nghĩa và cách sinh
<code>id</code>	string	non-null	ID object Meta lead giả lập, có định dạng <code>3280000000NNNN</code> ; là primary key của trình mô phỏng
<code>created_time</code>	string datetime	non-null	<code>Config.BASE_DATE + i*4 hours + random minute</code> , định dạng với offset <code>+0000</code>
<code>form_id</code>	string	non-null	ID lead form giả lập cố định <code>890000123456789</code>
<code>campaign_id</code>	string	non-null	ID campaign giả lập; hậu tố ngẫu nhiên từ 1 đến 4 nên có thể lặp lại
<code>campaign_name</code>	string	non-null	Nhãn campaign giả lập; được random độc lập từ 1 đến 4
<code>adset_id</code>	string	non-null	ID ad set giả lập; hậu tố ngẫu nhiên từ 1 đến 5
<code>adset_name</code>	string	non-null	Tên ad set giả lập cố định <code>Broad_Audience_18_65</code>
<code>ad_id</code>	string	non-null	ID ad giả lập; hậu tố ngẫu nhiên từ 1 đến 7
<code>ad_name</code>	string	non-null	Tên ad giả lập; hậu tố creative ngẫu nhiên từ 1 đến 7

Column	Type	Nullability	Ý nghĩa và cách sinh
field_email	string email	non-null	Câu trả lời email từ người giả lập dùng chung; Meta CIR key mạnh nhất
field_phone	string phone	non-null	Câu trả lời phone từ người giả lập dùng chung; là Meta CIR key mạnh nhất sau khi normalize
field_first_name	string	non-null	Câu trả lời first name trong form
field_last_name	string	non-null	Câu trả lời last name trong form
field_city	string	non-null	Câu trả lời city trong form
field_state	string	non-null	Câu trả lời state/province trong form
field_country	string ISO-like code	non-null	Câu trả lời country trong form, hiện là VN

Giới hạn của trình mô phỏng

- Tên `field_*` là tên column của trình mô phỏng, không phải bản sao trực tiếp của cấu trúc `field_data` lồng nhau trong response object của Meta.
- ID campaign, ad set và ad không được đảm bảo unique hoặc ổn định theo entity.
- Không mô phỏng quyền Meta API, access token, pagination khi lấy lead hoặc field webhook.

4. Metadata TikTok Integrated Reports

Nguồn tài liệu API

- Tổng quan API portal: [TikTok Marketing API reporting overview](#)
- Nhóm endpoint integrated report: `/open_api/v1.3/report/integrated/get/`

TikTok report bao gồm dimension và metric. Trình mô phỏng mô hình hóa một basic report ở cấp ad, được group theo ngày và country. API thực tế thường trả các giá trị số dưới dạng string trong JSON; CSV simulator này ghi các giá trị số Python, vì vậy CSV serializer sẽ ghi chúng không có dấu quote.

Metadata dataset

Hạng mục	Giá trị
File	tiktok_cir_api.csv
Grain	Một dòng ad/ngày báo cáo giả lập
Số dòng	Config.NUM_ROWS
Dimension	Advertiser, date, campaign, ad group, ad, country
Metric	Impressions, clicks, spend, CTR, CPC, CPM, conversions, conversion rate
Ngày báo cáo	stat_time_day
Định dạng ngày báo cáo	YYYY-MM-DD 00:00:00
Currency	Không khai báo rõ; spend là số tiền giả lập theo account currency

Metadata column

Column	Type	Nullability	Ý nghĩa và cách sinh
advertiser_id	string	non-null	ID advertiser giả lập cố định 710000123456789
stat_time_day	string datetime	non-null	Config.BASE_DATE + (i % 10) days, được chuẩn hóa về nửa đêm
campaign_id	string	non-null	ID campaign giả lập; hậu tố ngẫu nhiên từ 1 đến 4
campaign_name	string	non-null	Tên campaign giả lập; được random độc lập từ 1 đến 4
adgroup_id	string	non-null	ID ad group giả lập; hậu tố ngẫu nhiên từ 1 đến 5
adgroup_name	string	non-null	Tên ad group giả lập; hậu tố ngẫu nhiên từ 1 đến 5
ad_id	string	non-null	ID ad giả lập; hậu tố ngẫu nhiên từ 1 đến 7
ad_name	string	non-null	Tên ad giả lập; hậu tố ngẫu nhiên từ 1 đến 7
country_code	string ISO-like code	non-null	Chọn ngẫu nhiên từ VN, SG, TH; VN có bốn phần tử nên có trọng số cao hơn
impressions	integer	non-null	Số nguyên ngẫu nhiên từ 10.000 đến 20.000
clicks	integer	non-null	Cắt phần thập phân của impressions nhân với tỷ lệ ngẫu nhiên từ 1% đến 4%
spend	decimal	non-null	Làm tròn đến hai chữ số; clicks nhân với số ngẫu nhiên từ 0.3 đến 0.8
ctr	decimal percent	non-null	$\text{clicks} / \text{impressions} * 100$, làm tròn đến bốn chữ số
cpc	decimal	non-null	$\text{spend} / \text{clicks}$, làm tròn đến bốn chữ số; bằng zero nếu clicks bằng zero
cpm	decimal	non-null	$\text{spend} / \text{impressions} * 1000$, làm tròn đến bốn chữ số
conversion	integer	non-null	Cắt phần thập phân của clicks nhân với tỷ lệ ngẫu nhiên từ 1% đến 5%
conversion_rate	decimal percent	non-null	$\text{conversion} / \text{clicks} * 100$, làm tròn đến bốn chữ số; bằng zero nếu clicks bằng zero

Giới hạn của trình mô phỏng

- Không mô phỏng report request, access token, pagination, account timezone, account currency hoặc response envelope của API.
- ID dimension và name được random độc lập, vì vậy cùng một ID có thể nhận các name khác nhau giữa các row.

- Metric là ước lượng giả lập và không nên được xem là benchmark của nền tảng.

5. Metadata Google Analytics 4

Nguồn tài liệu API

- Schema Data API chính thức: [Google Analytics Data API dimensions and metrics](#)
- Các field cấu hình GA4: [Google Analytics configuration reference](#)
- Gửi identity sau khi đăng nhập: [Send user IDs](#)
- Gửi user data đã hash: [Send user-provided data using Measurement Protocol](#)
- Payload Measurement Protocol: [Measurement Protocol reference](#)
- Chính sách PII: [Best practices to avoid sending PII](#)

Dataset này sử dụng tên dimension và metric của Google Analytics Data API. Đây là projection CSV phẳng của các report row giả lập, không phải event record của GA4 BigQuery export.

Tích hợp attribution và identity trong GA4

UTM source và traffic từ Facebook Đối với website, GA4 có thể đọc campaign parameter từ landing URL, gồm `utm_source`, `utm_medium`, `utm_campaign`, `utm_id`, `utm_content` và `utm_term`. Các giá trị này được dùng cho những traffic-source dimension của GA4 như `sessionSource`, `sessionMedium`, `sessionCampaignName` và `sessionCampaignId`.

`utm_source=facebook` chỉ cho biết Facebook là traffic source; nó không định danh customer. `fbclid` của Meta là click identifier, không phải customer ID, `cid` hay authenticated user identity. Không được dùng `fbclid` làm CIR customer key. Nếu application lưu giá trị này để chẩn đoán campaign nội bộ, không đưa PII vào campaign parameter hoặc page URL và phải tuân thủ quy định privacy, retention của dự án.

Không được nhầm các identifier này với nhau: GA4 `client_id` định danh một browser hoặc app instance, GA4 `user_id` định danh user đã đăng nhập bằng giá trị non-PII do website sở hữu, `fbclid` định danh một lượt click quảng cáo Meta, còn `cid` trong simulator định danh một customer giả lập.

Simulator hiện sinh UTM field giả lập và `fbclid` chỉ cho traffic Facebook dưới dạng collection metadata. Các giá trị này đại diện cho input attribution từ landing page; không được lấy từ URL hoặc Facebook account thực tế.

Google SSO hoặc internal login Sau khi Google SSO hoặc internal login thành công, website có thể set `user_id` của GA4 thành một identifier ổn định, do website sở hữu và mang tính pseudonymous. Google xác định `user_id` là configuration value dành riêng để kết nối hoạt động giữa các session, device và platform. Giá trị này không được tự nó là PII. Không gửi nó dưới dạng custom user property, custom dimension hoặc event-level parameter.

Chỉ gửi `user_id` khi user đang authenticated. Khi logout, set giá trị thành `null`; không gửi empty string hoặc text "null". Simulator biểu diễn row anonymous bằng `user_id` rỗng và row authenticated bằng giá trị non-PII giả lập. CSV cũng có các collection field giả lập `client_id`, `user_pseudo_id` và `login_method`.

Email và phone đã hash Khi server-side integration sử dụng GA4 Measurement Protocol, user-provided data có thể được gửi trong object cấp cao nhất `user_data` cùng với `user_id`. Trong mô hình này, email và phone không phải event parameter thông thường. Measurement Protocol yêu cầu developer normalize dữ liệu, hash bằng SHA-256 và gửi giá trị dạng hex lowercase trong `sha256_email_address` và `sha256_phone_number`.

Quy tắc normalize được document gồm:

- Email: bỏ whitespace ở đầu/cuối, chuyển lowercase, bỏ space và bỏ dấu chấm trước domain với địa chỉ `gmail.com` hoặc `googlemail.com`, sau đó hash.
- Phone: bỏ mọi ký tự không phải chữ số, thêm prefix + theo dạng E.164, sau đó hash.

Chỉ gửi dữ liệu này khi đã đáp ứng các điều kiện consent, privacy và data governance cần thiết cho implementation. Không bao giờ gửi email hoặc phone raw trong GA4 URL, event parameter thông thường hoặc custom dimension. CSV simulator chỉ chứa giá trị fixture SHA-256 giả lập trong các column `sha256_*`, không chứa email hoặc phone raw.

Ví dụ shape của Measurement Protocol:

```
{
  "client_id": "WEB_CLIENT_ID",
  "user_id": "NON_PII_INTERNAL_USER_ID",
  "events": [{"name": "login", "params": {"method": "google_sso"}}],
  "user_data": {
    "sha256_email_address": ["SHA256_EMAIL_HEX"],
    "sha256_phone_number": ["SHA256_PHONE_HEX"]
  }
}
```

Các giá trị trong ví dụ chỉ là placeholder. Request thực tế còn yêu cầu credential và identifier phù hợp cho Measurement Protocol transport.

Metadata dataset

Hạng mục	Giá trị
File	ga4_cir_api.csv
Grain	Một event/report row giả lập
Số dòng	Config.NUM_ROWS
Date field	date
Định dạng date	YYYYMMDD
Event set	page_view, view_item, begin_checkout, purchase
Source set	google, facebook, tiktok, zalo
Revenue currency	Không khai báo rõ; giá trị là số tiền giả lập dạng VND
Mô hình key event	purchase tạo keyEvents = 1; các event khác tạo 0
Mô hình authentication	Mỗi row thứ ba là anonymous; các row khác dùng context login google_sso hoặc internal giả lập
Mô hình UTM	Giá trị utm_* giả lập và đồng bộ với session/campaign field
Mô hình user data	Row authenticated có email/phone SHA-256 giả lập; raw PII không bao giờ được sinh

Metadata column

Column	Type	Nullability	Ý nghĩa và cách sinh
date	string date	non-null	Ngày random từ ngày cơ sở đến 10 ngày sau đó, định dạng YYYYMMDD
eventName	string enum-like	non-null	Event giả lập random từ bộ bốn event
campaignId	string	non-null	ID giả lập dạng GAD-C360-NNN, hậu tố ngẫu nhiên từ 1 đến 4
campaignName	string	non-null	Tên web campaign giả lập, được random độc lập từ 1 đến 4
sessionSource	string enum-like	non-null	Chọn ngẫu nhiên từ google, facebook, tiktok, zalo
sessionMedium	string enum-like	non-null	Dự kiến là cpc với Google và paid_social với các source khác; implementation hiện tại so sánh cả danh sách source thay vì source đã chọn, nên hiện sinh paid_social cho mọi row

Column	Type	Nullability	Ý nghĩa và cách sinh
country	string ISO-like code	non-null	Country của người giả lập dùng chung, hiện là VN
city	string	non-null	City của người giả lập dùng chung
browser	string enum-like	non-null	Chọn ngẫu nhiên từ Chrome, Safari, Edge
deviceCategory	string enum-like	non-null	Chọn ngẫu nhiên từ mobile, desktop, tablet
platform	string enum-like	non-null	Giá trị cố định web
sessionCampaignId	string	non-null	Cùng giá trị được sinh cho campaignId
sessionCampaignName	string	non-null	Tên session campaign giả lập; được random độc lập từ 1 đến 4
transactionId	string	rỗng với non-purchase	ORD-NNNNN với row purchase; rỗng trong các row khác
eventCount	integer	non-null	Số nguyên ngẫu nhiên từ 1 đến 5
keyEvents	integer	non-null	1 với purchase và 0 với các event khác; dùng tên metric GA4 hiện đại
totalRevenue	decimal	non-null	Từ 450.000 đến 950.000 với purchase; 0 với các event khác
engagementRate	decimal fraction	non-null	Fraction ngẫu nhiên từ 0.35 đến 0.85; theo quy ước fraction của GA4
client_id	string	non-null	Browser/app collection identifier giả lập, unique theo generated row; không phải customer ID
user_pseudo_id	string	non-null	GA4 collection identifier pseudonymous giả lập, unique theo generated row
user_id	string	rỗng với anonymous row	Site-owned identifier non-PII giả lập dạng GA4-CUST-NNNN với authenticated row
login_method	string	rỗng với anonymous row	Authentication context giả lập: google_sso hoặc internal
utm_source	string	non-null	Attribution source giả lập từ landing page; bằng sessionSource
utm_medium	string	non-null	Attribution medium giả lập từ landing page; bằng sessionMedium, cpc với Google và paid_social với source khác
utm_campaign	string	non-null	Campaign name giả lập từ landing page; bằng campaignName và sessionCampaignName

Column	Type	Nullability	Ý nghĩa và cách sinh
utm_id	string	non-null	Campaign ID giả lập từ landing page; bằng campaignId và sessionCampaignId
fbclid	string	rỗng trừ Facebook row	Click identifier Meta giả lập khi utm_source là facebook; không bao giờ là customer key
sha256_email_address	string SHA-256 hex	rỗng với anonymous row	Email giả lập đã normalize và hash thành SHA-256 lowercase hexadecimal cho user data dạng Measurement Protocol
sha256_phone_number	string SHA-256 hex	rỗng với anonymous row	Phone giả lập bỏ về digits, thêm +, sau đó hash thành SHA-256 lowercase hexadecimal

Giới hạn của trình mô phỏng

- sessionSource không được liên kết với session hoặc user identifier thực tế.
- sessionCampaignName và campaignName không được đảm bảo tương ứng với ID của chúng.
- Không có userPseudoId, session ID, event timestamp, item array, user property, ecommerce item hoặc request/response envelope của GA4.
- client_id, user_pseudo_id, user_id, UTM field, fbclid và các field sha256_* dạng phẳng là collection metadata của simulator; không phải tất cả đều query được như standard dimension của Google Analytics Data API.
- File này không khai báo currency cho totalRevenue.
- Implementation của sessionMedium hiện có lỗi semantic được mô tả ở trên; consumer không nên suy luận rằng source-medium được sinh đúng cho đến khi lỗi được sửa.

6. Metadata Zalo Official Account

Nguồn tài liệu API

- Documentation chính thức: [Zalo Official Account API](#)
- Get User Detail v3.0: [Zalo Get User Detail](#)
- Endpoint được đại diện: /v3.0/oa/user/detail

Mô hình Zalo OA hiện tại là operation User Detail v3.0. Response thực tế chứa dữ liệu shared information dạng lồng nhau. Dataset này làm phẳng các thuộc tính profile và shared-info đã chọn thành các column CSV.

Metadata dataset

Hạng mục	Giá trị
File	zalo_cir_api.csv
Grain	Một profile user Zalo giả lập
Số dòng	Config.NUM_ROWS
Source identifier chính	user_id
Identity field	display_name, shared_info_name, shared_info_phone, shared_info_city, shared_info_address
Privacy/sensitivity field	is_sensitive, user_is_follower
Flattening	Các column shared_info_* đại diện cho giá trị được trích xuất từ object shared_info thực tế

Metadata column

Column	Type	Nullability	Ý nghĩa và cách sinh
user_id	string integer	non-null	User ID Zalo giả lập, base 567826391599986760 cộng với row index
user_id_by_app	string integer	non-null	User ID theo app giả lập, base 567826390000000000 cộng với row index
display_name	string	non-null	Tên đầy đủ của người giả lập dùng chung
user_gender	integer enum-like	non-null	Mã gender của người dùng; comment trong code quy định 1 nam, 2 nữ, 0 khác/không xác định
is_sensitive	boolean	non-null	Cố định là False; đại diện việc profile data trả về có nhạy cảm hay không
user_is_follower	boolean	non-null	Cố định là True; đại diện trạng thái follower
shared_info_name	string	non-null	Name được làm phẳng từ object shared_info giả định
shared_info_phone	string phone	non-null	Phone được làm phẳng từ object shared_info; là identity field cho CIR
shared_info_city	string	non-null	City được làm phẳng từ object shared_info
shared_info_address	string	non-null	Địa chỉ giả lập dạng Sample street N, city
tags_and_notes_info	string enum-like	non-null	Label giả lập từ bốn tag tiếng Việt; không phải profile identity field được document

Giới hạn của trình mô phỏng

- CSV không phải raw JSON response và không giữ lại object shared_info.
- tags_and_notes_info là enrichment riêng của trình mô phỏng, không thuộc projection identity user được mô tả trong tài liệu này.
- Không mô phỏng permission, access token, follower authorization, hành vi privacy hoặc response error envelope của Zalo.
- Documentation Zalo được render qua portal dùng nhiều JavaScript; cần đối chiếu field response với example v3.0 trực tiếp trước khi dùng CSV này làm integration fixture.

7. Metadata AppsFlyer Pull API Raw Data

Nguồn tài liệu API

- Pull API raw data: [AppsFlyer Pull API raw data](#)
- Raw data field dictionary: [AppsFlyer raw data field dictionary](#)

AppsFlyer raw-data report sử dụng schema rộng và phụ thuộc vào từng report. Field có thể rỗng hoặc không khả dụng tùy report type, platform, attribution source, privacy setting và delivery method. Trình mô phỏng này mô hình hóa in-app-event report với một tập field Pull API canonical đã chọn.

Metadata dataset

Hạng mục	Giá trị
File	appsflyer_cir_api.csv
Grain	Một AppsFlyer in-app event giả lập
Số dòng	Config.NUM_ROWS
Identity field	customer_user_id, JSON event_value.customer_id, device identifier
Event set	af_login, af_content_view, af_add_to_cart, af_purchase
Định dạng thời gian	YYYY-MM-DD HH:MM:SS, không có timezone rõ ràng
Định dạng event value	JSON string; row purchase có customer_id và order_id
Revenue currency	Cố định là VND với row có revenue giả lập

Metadata column

Column	Type	Nullability	Ý nghĩa và cách sinh
attributed_touch_type	string enum-like	non-null	Chọn ngẫu nhiên click hoặc impression; loại engagement dùng cho attribution
attributed_touch_time	string datetime	non-null	Install time trừ ngẫu nhiên từ 5 đến 60 phút
install_time	string datetime	non-null	Ngày cơ sở cộng ngẫu nhiên 0 đến 5 ngày và 1 đến 12 giờ
event_time	string datetime	non-null	Install time cộng ngẫu nhiên từ 5 đến 120 phút
event_name	string enum-like	non-null	AppsFlyer event name random từ bộ bốn event
event_value	string JSON	non-null	JSON chứa customer_id; row purchase có thêm order_id
event_revenue	decimal	non-null	Từ 100.000 đến 500.000 với purchase; 0 trong các row khác
event_revenue_currency	string currency code	non-null	Cố định là VND
event_source	string enum-like	non-null	Cố định là SDK
media_source	string enum-like	non-null	Chọn random facebook, tiktok, googleadwords_int hoặc zalo
channel	string	non-null	Label hiển thị random: Facebook Ads, TikTok Ads, Google Ads hoặc Zalo
campaign	string	non-null	Tên campaign giả lập; hậu tố random từ 1 đến 4
campaign_id	string	non-null	ID AppsFlyer giả lập dạng AF-CAMP-NNN
adset	string	non-null	Tên ad set giả lập; hậu tố random từ 1 đến 5
adset_id	string	non-null	ID ad set giả lập dạng AF-AS-NNN
ad	string	non-null	Tên creative giả lập; hậu tố random từ 1 đến 7

Column	Type	Nullability	Ý nghĩa và cách sinh
ad_id	string	non-null	ID ad giả lập dạng AF-AD-NNN
country_code	string ISO-like code	non-null	Country của người giả lập dùng chung, hiện là VN
state	string	non-null	State/province của người giả lập dùng chung
city	string	non-null	City của người giả lập dùng chung
postal_code	string	non-null	Postal code giả lập dạng sáu chữ số, từ 700010 đến 700099
ip	string IPv4-like	non-null	Địa chỉ dạng IPv4 giả lập bắt đầu bằng 103.21.
operator	string	non-null	Chọn random Viettel, MobiFone hoặc VinaPhone; dùng đúng tên field trong AppsFlyer dictionary hiện tại
language	string BCP-47-like	non-null	Cố định là vi
appsflyer_id	string	non-null	ID trông giống ID do SDK sinh; segment hai chữ số random nên không đảm bảo unique
advertising_id	string UUID-like	non-null	Advertising ID có thể reset giả lập; hậu tố theo row index giúp unique trong simulator
idfa	string	rỗng trên Android	Advertising identifier iOS giả lập; rỗng khi is_android là True
android_id	string	rỗng trên iOS	Android identifier giả lập; rỗng khi is_android là False
customer_user_id	string	non-null	cid giả lập dùng chung; AppsFlyer-to-CIR key mạnh nhất
idfv	string	rỗng trên Android	iOS vendor identifier giả lập; rỗng khi is_android là True
platform	string enum-like	non-null	android hoặc ios, được chọn bởi is_android
device_type	string	non-null	Nhãn device model giả lập; AppsFlyer dictionary cho biết field này đã deprecated/không còn được populate và nên dùng device model trong report hiện tại
os_version	string	non-null	Android random 14/15 hoặc iOS random 17.6/16.7
app_version	string	non-null	Cố định là 6.8.1
sdk_version	string	non-null	Cố định là 6.15.0

Column	Type	Nullability	Ý nghĩa và cách sinh
app_id	string	non-null	App ID giả lập cố định com.example.customer360
bundle_id	string	non-null	Bundle/app ID giả lập cố định com.example.customer360
user_agent	string	non-null	User agent dạng browser giả lập cho Android hoặc iOS
http_referrer	string URL	non-null	Landing URL giả lập cố định
original_url	string URL	non-null	App URL giả lập chứa cid của người dùng

Giới hạn của trình mô phỏng

- Đây là một subset được chọn từ AppsFlyer main schema, không phải bản export đầy đủ của raw-data field dictionary.
- Timestamp string không có timezone, trong khi timezone thực tế của AppsFlyer phụ thuộc delivery method và account setting.
- Các giá trị attribution hierarchy được random độc lập và không mô hình hóa entity campaign ổn định.
- appsflyer_id có thể collision vì chỉ dùng một suffix random giới hạn; không dùng nó làm unique key được đảm bảo trong test.
- Device identifier là dữ liệu giả lập và không được hiểu là device identity thực tế.

8. Metadata CIR liên nền tảng

Khả dụng của identity key

Nền tảng	Key dùng chung mạnh nhất	Key phụ trợ	Có column cid trực tiếp?
Meta	field_email, field_phone	First/last name, city, state	Không
TikTok	Không có	Advertiser/campaign hierarchy và country	Không
GA4	Không có trong schema hiện tại; GA4 production có thể dùng user_id không chứa PII	City, country, campaign/source context, traffic dimension tùy chọn sinh từ UTM	Không
Zalo AppsFlyer	shared_info_phone customer_user_id, event_value.customer_id	Name, city, address Original URL, device identifier, geography	Không Có, nhưng được nhúng trong field chứ không phải column riêng

Mapping row-người dùng giả lập dự kiến

- Meta, GA4, Zalo và AppsFlyer chọn người dùng dùng chung theo chu kỳ.
- Với 20 row và 8 người, vị trí người dùng sẽ lặp lại sau mỗi tám row.
- TikTok row là quan sát quảng cáo tổng hợp và cố ý không có identity cấp cá nhân.
- CIR thực tế nên normalize email và phone trước khi matching; name, city và device identifier nên được xem là bằng chứng hỗ trợ, không phải identifier unique được đảm bảo.

Chất lượng dữ liệu và khả năng tái lập

- Module seed global random generator của Python bằng 42 tại thời điểm import.
- Import module có side effect: tạo output directory đã cấu hình và thay đổi random sequence dùng chung của process.

- Khả năng tái lập giả định cùng Python implementation, execution order, configuration và generator code.
- CSV được serialize từ các giá trị Python; ingestion downstream nên cast rõ ràng các field numeric, boolean, date, datetime và JSON-string thay vì dựa vào type inference.

9. Thuật toán CIR liên nền tảng

Phần này mô tả thuật toán tham chiếu trong `all-data-simulator/test_cir.py`. Đây là implementation deterministic để kiểm tra identity stitching trên dữ liệu simulator, không phải production identity engine.

9.1. Input và nguyên tắc

Thuật toán đọc các file CSV sau từ `./all-data-simulator/platform_cir_csv`:

Nguồn	Grain	Vai trò trong CIR
<code>meta_cir_api.csv</code>	Một lead	Cung cấp email và phone để nối identity
<code>zalo_cir_api.csv</code>	Một profile user	Cung cấp phone để nối identity
<code>appsflyer_cir_api.csv</code>	Một in-app event	Cung cấp <code>customer_user_id</code> , device ID và transaction ID
<code>ga4_cir_api.csv</code>	Một event/report row	Nối bằng <code>transactionId</code> khi có giá trị
<code>tiktok_cir_api.csv</code>	Một ad/reporting-day row	Dữ liệu aggregate; không có identity cấp customer

File không tồn tại được loader bỏ qua bằng cách trả về danh sách rỗng. CSV được đọc bằng `utf-8-sig` để tương thích với UTF-8 BOM do simulator ghi ra.

9.2. Identity graph

Graph sử dụng cấu trúc `disjoint-set` (union-find):

- `parent`: map mỗi identifier về parent identifier của nó.
- `records`: map identifier tới các raw record được gắn vào identifier đó.
- `find(node)`: tìm root identity và thực hiện path compression.
- `union(node1, node2)`: đưa hai identifier vào cùng một connected component.
- `add_record(node, platform, record)`: gắn record vào identifier tương ứng.

Identifier được namespace theo prefix để tránh collision giữa các loại ID:

Prefix	Ví dụ	Ý nghĩa
CUID:	CUID:CUST-0001	Customer ID trong CDP Master Profile bridge hoặc AppsFlyer
EMAIL:	EMAIL:an.nguyen@example.test	Email identity
PHONE:	PHONE:84901234001	Phone identity
META:	META:328000000000001	Meta lead ID
ZALO:	ZALO:567826391599986760	Zalo user ID
AF:	AF:174000000010-a1b2c3d4e5f6	AppsFlyer ID
TXN:	TXN:ORD-00003	Transaction/order ID

9.3. CDP Master Profile bridge giả lập

Trong production, bridge này nên đến từ CDP Master Profile hoặc Customer 360 database. Trong simulator, `test_cir.py` khai báo tám user cố định với `cuid`, `email` và `phone`. Với mỗi user, thuật toán thực hiện:

```
CUID:cuid <-> EMAIL:email
CUID:cuid <-> PHONE:phone
```

Bridge này tạo điểm nối trung tâm giữa dữ liệu có PII-like field từ Meta/Zalo và customer_user_id từ AppsFlyer. Dữ liệu thực tế phải được normalize trước khi tạo key và phải tuân thủ tenant boundary, consent và privacy policy.

9.4. Quy tắc nối theo từng nguồn

Meta Lead Ads Với mỗi row có đủ field_email và field_phone:

1. Tạo EMAIL:<field_email> và PHONE:<field_phone>.
2. Tạo META:<id> từ Meta lead ID.
3. Union email với phone.
4. Union phone với Meta lead ID.
5. Gắn raw row vào node META:<id>.

Hiện tại code bỏ qua Meta row nếu thiếu email hoặc phone. Name, city và campaign field không được dùng để matching.

Zalo Official Account Với mỗi row có shared_info_phone:

1. Tạo PHONE:<shared_info_phone>.
2. Tạo ZALO:<user_id>.
3. Union phone với Zalo user ID.
4. Gắn raw row vào node Zalo.

Zalo hiện chỉ dùng phone làm join key; display_name, address và city chỉ nằm trong timeline record.

AppsFlyer Với mỗi row:

1. Tạo CUID:<customer_user_id> và AF:<appsflyer_id>.
2. Union customer ID với AppsFlyer ID.
3. Parse event_value từ JSON string.
4. Nếu JSON có order_id, tạo TXN:<order_id> và union transaction với CUID.
5. Gắn raw row vào node AppsFlyer.

Nếu event_value không phải JSON hợp lệ, parser bỏ qua transaction link nhưng vẫn giữ lại AppsFlyer record.

GA4 Với mỗi row có transactionId:

1. Tạo TXN:<transactionId>.
2. Gắn GA4 row vào node transaction.

Đây là join key GA4 duy nhất được test_cir.py sử dụng hiện tại. Các field mới trong simulator như user_id, user_pseudo_id, sha256_email_address, sha256_phone_number, utm_* và fbclid chưa được dùng trong graph này.

TikTok TikTok không được đưa vào identity graph vì dataset chỉ chứa số liệu quảng cáo aggregate như impressions, clicks, spend và conversion. Không suy luận customer identity từ advertiser_id, campaign ID, ad ID hoặc country_code.

9.5. Gom nhóm unified profile

Sau khi hoàn tất các phép union:

1. Duyệt toàn bộ node trong parent và gọi find(node) để lấy root.
2. Gom tất cả identifier vào profiles[root].identifiers.
3. Duyệt các record đã gắn trong records.
4. Gọi find(node) của từng record để đưa record vào profiles[root].timeline.
5. Chỉ giữ profile có ít nhất một record trong timeline.

Kết quả mỗi profile có dạng khái niệm:


```
{
  "identifiers": ["CUID:CUST-0001", "EMAIL:...", "META:..."],
  "timeline": [
    {"platform": "Meta Lead Ads", "data": {"...": "..."}},
    {"platform": "AppsFlyer", "data": {"...": "..."}}
  ]
}
```

test_cir.py in summary hai profile đầu tiên, liệt kê identifier và đếm số record theo platform. Với dữ liệu mặc định hiện tại, lần chạy kiểm tra đã tạo được 13 unified profile có timeline.

9.6. Luồng thuật toán

```
Load CSV sources
  |
  v
Create CDP Master Profile bridge: CUID <-> EMAIL/PHONE
  |
  v
Add Meta, Zalo, AppsFlyer and GA4 identity edges
  |
  v
Find roots with path compression
  |
  v
Group identifiers and records by root
  |
  v
Return unified profiles with cross-platform timeline
```

9.7. Các giới hạn cần biết

- Email và phone hiện được so sánh dạng raw; chưa có normalize nhất quán về case, whitespace, country code hoặc E.164.
- Hash email/phone của GA4 chỉ có thể match với hash được tạo từ cùng quy tắc normalize; không được giải hash để lấy PII.
- fbclid, UTM source/medium và campaign field là attribution metadata, không phải identity key.
- Không có confidence score, survivorship rule, conflict resolution hoặc manual review.
- Union là quan hệ bắc cầu: một key sai có thể làm nhiều record bị over-merge.
- CDP Master Profile bridge đang hard-code trong test và chưa có tenant isolation, audit trail hoặc consent enforcement.
- AppsFlyer appsflyer_id và device identifier là key kỹ thuật; không nên dùng riêng chúng làm customer identity chắc chắn.
- GA4 row không có transactionId sẽ không được nối vào profile trong implementation hiện tại, dù row có thể có user_id hoặc hash identity.

9.8. Hướng mở rộng production

1. Tạo canonical identity index từ CDP Master Profile với tenant-aware key và audit metadata.
2. Normalize email, phone và các identifier trước khi lookup.
3. Match GA4 user_id với một mapping non-PII trong backend; không dùng email/phone raw làm user_id.
4. Match sha256_email_address và sha256_phone_number với hash index tương ứng, chỉ khi có consent và đúng data-governance policy.
5. Giữ utm_* và fbclid trong attribution context; không đưa chúng vào identity graph.
6. Thêm confidence score, rule ưu tiên key mạnh, conflict queue và human review cho các match không chắc chắn.
7. Khi dữ liệu lớn, thay union-find in-memory bằng identity graph/service có persistence, partition theo tenant và cơ chế replay/audit.