

Customer Identity Resolution (CIR)

Trong nền tảng Customer 360

Giải pháp hợp nhất danh tính khách hàng đa nguồn
(AppsFlyer · MoEngage · Web Tracking · Core Banking)

Nội dung

1. Giới thiệu Customer Identity Resolution trong Customer 360
2. Nền tảng dữ liệu: nguồn dữ liệu, hành trình khách hàng, thuộc tính hồ sơ
3. Kiến trúc chi tiết: thiết kế hệ thống, các bước xử lý, phương pháp ghép nối
4. Demo thực tế

1. Giới thiệu Customer Identity Resolution

Vấn đề: dữ liệu khách hàng bị phân mảnh

Một khách hàng thực tế "chạm" vào doanh nghiệp qua **nhiều hệ thống độc lập**:

- **AppsFlyer** – attribution quảng cáo mobile (Facebook/TikTok/Google/Grab Ads...)
- **MoEngage** – engagement / marketing automation
- **Web Tracking** – cookie trên website và Google Analytics 4 (GA4)
- **Core Banking / KYC** – hệ thống lõi ngân hàng (retail & banking domain)
- **QR Code & Landing Page** - sự kiện offline (PR event, tại điểm bán...)

➡ Mỗi hệ thống chỉ biết **một phần** của khách hàng → không có góc nhìn 360°.

Customer Identity Resolution (CIR) là gì?

CIR là quá trình **liên kết (link)** các bản ghi hồ sơ thô (raw profile) từ nhiều nguồn khác nhau, xác định chúng có **cùng thuộc về một khách hàng thực** hay không, và **hợp nhất (merge)** thành **một hồ sơ "vàng" duy nhất** (Golden/Master Profile).

Mục tiêu trong Customer 360:

- Một khách hàng = **một master_profile_id** duy nhất, xuyên suốt mọi kênh, mọi domain (retail/banking/real_estate/travel)
- Nền tảng cho: personalization, chấm điểm (lead/churn/CLV), segmentation, báo cáo

Vì sao Customer Identity Resolution (CIR) rất quan trọng?

- Người dùng VN dùng **hiều app/thiết bị** (Zalo, app ngân hàng, app bán lẻ, web) → danh tính bị tách rời qua `device_id`, `cookie_id`, số điện thoại, email
- Ngân hàng số & bán lẻ đa kênh cần **tuân thủ dữ liệu cá nhân** (Nghị định 13/2023/NĐ-CP về bảo vệ dữ liệu cá nhân) → CIR phải xử lý PII đã **hash/ẩn danh**
- Chiến dịch marketing đa kênh (Facebook/TikTok/Google/Grab Ads) cần đo lường **hiệu quả thực sự trên một khách hàng**, không tính trùng theo từng thiết bị/click

2. Nền tảng dữ liệu

Nguồn dữ liệu (Data Sources)

Nguồn	Domain	Định danh mang theo
AppsFlyer	Mobile App	device_id , advertising_id (IDFA/GAID)
MoEngage	Mobile App	external_customer_id , email , push_token
Web Tracking	Landing Page	cookie_id , email
Core Banking / KYC	Core Banking	phone_number , national_id , device_id

Tất cả đổ về **một bảng staging duy nhất**: `cdp_raw_profiles_stage`
(đa tenant – `tenant_id` , đa domain – bán lẻ / banking / bất động sản / du lịch)

Hành trình khách hàng (Customer Journey Mapping)

Một khách hàng thực đi qua nhiều **điểm chạm (touchpoint)**, mỗi điểm chạm sinh ra **một raw profile riêng**:

```
graph LR
  A["install<br/>(ảnh danh: chỉ có<br/>device_id/advertising_id)"] --> B["login<br/>(email/phone)"]
  B --> C["product_view<br/>(retail banking)"]
  B --> D["kyc_completed<br/>(banking: national_id)"]
  D --> E["loan_application<br/>(banking)"]
  C --> F["Remarketing<br/>(web/app)"]
```

- Điểm chạm đầu (`install`) **không có PII** — chỉ có định danh thiết bị/quảng cáo -> Anonymous Profile
- Các điểm chạm sau (`login` , `kyc_completed` ...) **trên cùng thiết bị** mới có danh tính thật
- CIR phải **liên kết các Anonymous Profile vào 1 Master Profile** → đây chính là cơ chế tạo ra "duplicate" cần hợp nhất

Thuộc tính hồ sơ chính (Key Profile Attributes)

Nhóm định danh thông tin cá nhân (luôn hash SHA-256 trước khi lưu — không lưu PII thô):

`full_name`, `email`, `phone_number`, `national_id`

Nhóm định danh thiết bị/quảng cáo (hợp nhất thành mảng trên master):

`device_id` → `device_ids[]`, `advertising_id` → `advertising_ids[]`, `cookie_id` → `cookie_ids[]`

Nhóm định danh theo hệ thống nguồn (hợp nhất thành JSONB theo `source_system`):

`external_customer_id` → `external_ids{}`, `push_token` → `push_tokens{}`

Metadata mô tả tất cả attribute: bảng `cdp_profile_attributes` — schema hỗ trợ mô tả toàn bộ ~60 cột của `cdp_master_profiles` (cấu hình *matching_rule*, *matching_threshold*, *consolidation_rule*, *is_pii*, *attribute_group*: SYSTEM/IDENTITY/RETAIL/BANKING/SCORING...). Bản seed demo hiện tại (`scripts/init_sample_data.py`) chỉ nạp **8 thuộc tính** dùng trực tiếp cho identity resolution (`email`, `phone_number`, `national_id`, `device_id`, `advertising_id`, `cookie_id`, `external_customer_id`, `full_name`) — phần metadata mô tả đầy đủ các thuộc tính còn lại chưa được seed.

3. Kiến trúc chi tiết

Sơ đồ kiến trúc hệ thống

```
graph TD
    A["Nguồn dữ liệu<br/>AppsFlyer/MoEngage/Web/Core Banking"] --> B["Data Ingestion Worker"]
    B --> C["cdp_raw_profiles_stage<br/>(PostgreSQL 16, status_code=1)"]

    B -- "sau mỗi insert" --> T["IdentityResolutionTrigger<br/>.attempt_trigger()"]
    T -- "FOR UPDATE NOWAIT<br/>throttle N giây" --> ST["cdp_id_resolution_status"]
    T -- "nếu qua throttle" --> R["CustomerIdentityResolver<br/>.run_resolution_batch()"]

    S["Lịch trình hàng ngày<br/>(Cron/Airflow, drain-loop)"] --> R

    M["cdp_profile_attributes<br/>(matching rules)"] --> R
    C -- "đọc status_code=1" --> R
    R --> E["cdp_master_profiles"]
    R --> F["cdp_profile_links"]
    R -- "status_code=3" --> C

    E --> G["Customer 360 View"]
    F --> G
    G --> H["FastAPI Reporting API"]
```

Nguyên tắc thiết kế: Metadata-driven

- Quy tắc ghép nối **không hard-code trong code** mà đọc động từ bảng `cdp_profile_attributes`
- Mỗi thuộc tính khai báo: `is_identity_resolution`, `matching_rule`, `matching_threshold`
- Thêm/sửa quy tắc ghép nối = **UPDATE 1 dòng metadata**, không cần deploy lại code
- Resolver chỉ lấy các rule đang **ACTIVE** và có `matching_rule != 'none'`

```
SELECT attribute_internal_code, matching_rule, matching_threshold
FROM cdp_profile_attributes
WHERE is_identity_resolution = TRUE
      AND status = 'ACTIVE'
      AND matching_rule IS NOT NULL AND matching_rule != 'none';
```

Các bước xử lý (Process Steps)

Cho mỗi batch (tối đa `batch_size` bản ghi, `status_code = 1`):

1. **Lấy quy tắc ghép nối đang active** từ `cdp_profile_attributes`
2. **Lấy batch raw profile** chưa xử lý, cùng `tenant_id`
3. Với mỗi raw profile → `_find_master_profile()`: build câu `WHERE` động (OR các điều kiện match), scope theo `tenant_id` + `domain`
4. **Có match** → `_link_and_update()`: insert `cdp_profile_links`, `UPDATE` master (COALESCE cho scalar, append-distinct cho mảng/JSONB)
5. **Không match** → `_create_master_and_link()`: tạo `cdp_master_profiles` mới + link
6. **Đánh dấu đã xử lý**: `status_code = 3`, `processed_at = NOW()`
7. `COMMIT` toàn batch — an toàn để **retry** (idempotent nhờ unique constraint (`tenant_id`, `raw_profile_id`))

Identity Resolution — Các phương pháp ghép nối

Phương pháp	Dùng cho	Điều kiện
Exact Match	email, phone, national_id, full_name (hash), external_customer_id	col = value
Fuzzy (Trigram)	Văn bản thô	similarity >= threshold
Double Metaphone	Họ tên phát âm gần giống	dmetaphone(col) = dmetaphone(value)
Array Match	device_id, advertising_id, cookie_id	value = ANY(array)
JSONB Match	external_customer_id theo từng nguồn	external_ids @> {...}

Identity Resolution — Bảo vệ PII & Chuẩn AdTech

Chuẩn xử lý PII

- PII (`email` , `phone` , `national_id` , `full_name`) được **hash bằng SHA-256** trước khi lưu trữ.
- Chuẩn hóa dữ liệu (lowercase, trim, E.164...) **trước khi hash** để tăng tỷ lệ match.
- Cột `is_hashed` `BOOLEAN` trên `cdp_master_profiles` đánh dấu hồ sơ có PII đã hash.
- **Ràng buộc:** `is_hashed = TRUE` $\Rightarrow$ `persona_name` **bắt buộc khác NULL** (CHECK constraint DB + tự sinh ở tầng Python — `persona.py`) — nhãn dễ đọc, không phải PII, thay thế `full_name` (giờ chỉ còn là hash) cho mục đích duyệt/tìm kiếm ngữ nghĩa. Ví dụ: `"Savvy Retail Shopper (TikTok Ads) #4f2a9c"` .

Quy tắc ghép nối

Loại dữ liệu	Phương pháp
PII đã hash	✓ Exact Match
Văn bản thô	✓ Fuzzy Match (Trigram, Double Metaphone)

Tham chiếu chuẩn ngành

- **Google Customer Match**: hỗ trợ upload PII đã hash bằng **SHA-256**.
- **Google Enhanced Conversions**: yêu cầu chuẩn hóa dữ liệu trước khi hash và đối sánh bằng giá trị hash.
- Mô hình này cũng được áp dụng rộng rãi trên các nền tảng AdTech/MarTech như **Meta Customer Match**.

Reference

- Google Customer Match <https://support.google.com/displayvideo/answer/9539301>
- Google Enhanced Conversions <https://support.google.com/adspolicy/answer/9755941>

Cơ chế Real-time vs Batch hàng ngày

Real-time (throttled), không phải DB trigger thật:

- Ingestion worker gọi `IdentityResolutionTrigger.attempt_trigger()` ngay sau insert
- Dùng `SELECT ... FOR UPDATE NOWAIT` trên `cdp_id_resolution_status` → khoá theo hàng, nhiều worker song song vẫn an toàn
- Nếu đã chạy trong N giây gần nhất → **bỏ qua** (throttle), không chặn luồng ingest
- Lỗi xử lý CIR **không làm crash** worker ingest (bắt exception, rollback)

Batch hàng ngày (`daily_job.py`):

- Drain-loop: lặp `run_resolution_batch()` cho đến khi staging hết bản ghi `status_code=1`
- Đảm bảo **không sót** bản ghi nếu real-time bị throttle bỏ qua liên tục

Đa tenant & đa domain (Multi-tenant / Multi-domain)

- Mọi bảng đều có `tenant_id` — cách ly dữ liệu giữa các khách hàng doanh nghiệp (multi-tenant SaaS)
- `domain` phân biệt **retail** vs **banking** trong cùng một tenant → **không hợp nhất** hồ sơ giữa hai domain (một người có thể là khách bán lẻ và khách vay ngân hàng, được resolve **riêng**)
- Mọi câu query ghép nối luôn `WHERE tenant_id = %s AND domain = %s`
- `cdp_profile_links` có unique constraint `(tenant_id, raw_profile_id)`

4. Demo thực tế

Kịch bản demo

`backend-system/identity_resolution/run-demo.sh` — một lệnh, chạy toàn bộ pipeline:

1. Nạp cấu hình DB từ `.env`, dựng virtualenv, cài `requirements.txt`
2. `init_sample_data.py` — sinh **1.000 raw profile** AppsFlyer giả lập:
 - 6 kênh quảng cáo (Facebook/TikTok/Google/Grab/FPT Play Ads, PR offline)
 - Trộn domain retail/banking (40% banking)
 - ~30% là **"duplicate" có chủ đích**: sự kiện `login/purchase/kyc_completed` trên **cùng device** của một `install` ẩn danh trước đó
 - PII được **hash SHA-256** trước khi insert (không lưu dữ liệu thật)
3. `run_demo_resolution.py` — chạy `CustomerIdentityResolver` cho đến khi hết batch, in kết quả master profile

Kết quả demo (đã verify thực tế)

Chỉ số	Giá trị
Raw profiles đầu vào	1.000
Master profiles tạo ra	700
Master profile được hợp nhất (≥ 2 raw)	243
Tỷ lệ trùng chủ đích	30% (<code>duplicate_rate</code>)

➡ Chuỗi `install (device_id)` → `login/kyc_completed (phone/email/national_id)` được **CIR** nối lại đúng qua `device_id`, dù `install` ban đầu hoàn toàn ẩn danh.

Lưu ý kỹ thuật đã gặp: phải đảm bảo `full_name` / `phone_number` sinh ngẫu nhiên **không trùng lặp** giữa các khách hàng khác nhau (rejection-sampling), nếu không resolver sẽ hợp nhất nhầm 2 người thật thành 1.

Kiểm tra kết quả bằng SQL

```
-- Master profile theo domain (PII hiển thị là hash, persona_name là nhãn dễ đọc thay thế)
SELECT master_profile_id, domain, full_name, email, phone_number, is_hashed, persona_name, source_systems
FROM customer360.cdp_master_profiles
WHERE tenant_id = '11111111-1111-1111-1111-111111111111'
ORDER BY domain;

-- Trạng thái xử lý của từng raw profile
SELECT raw_profile_id, source_system, domain, status_code
FROM customer360.cdp_raw_profiles_stage
WHERE tenant_id = '11111111-1111-1111-1111-111111111111';

-- Liên kết raw -> master
SELECT * FROM customer360.cdp_profile_links
WHERE tenant_id = '11111111-1111-1111-1111-111111111111';
```

Quan sát qua API báo cáo (customer360-api)

FastAPI + SQLAlchemy 2, phản chiếu đúng dữ liệu demo:

- `GET /api/v1/reporting/summary` — tổng số raw/master, tỷ lệ hợp nhất
- `GET /api/v1/reporting/master-profiles/duplicates` — các master được hợp nhất từ ≥ 2 raw profile
- `GET /api/v1/reporting/identity-graph/coverage` — độ phủ định danh (device/email/phone...) trên master profile

➡ Cùng một nguồn sự thật (`customer360` schema) phục vụ cả **pipeline CIR** và **API báo cáo/ứng dụng**.

Tổng kết

- CIR biến N bản ghi rời rạc, đa nguồn, đa kênh thành **1 hồ sơ khách hàng duy nhất**
- Thiết kế **metadata-driven**, đa tenant/đa domain, xử lý **real-time (throttled) + batch** hàng ngày
- PII được **hash trước khi lưu** — tuân thủ bảo vệ dữ liệu cá nhân
- Demo thực tế: **1.000** → **700** hồ sơ, verify end-to-end trên PostgreSQL 16 + pgvector

Nền tảng cho: Customer 360 · Segmentation · Personalization · Lead/Churn/CLV Scoring